

Arquitectura de Despliegue

Analisis de Satisfaccion del Cliente - Sector BPO

Sistema de clasificacion automatica de comentarios de insatisfaccion mediante NLP y LLM (Gemini 2.5 Flash), con clustering semantico para descubrimiento de patrones.


Autor:	Mateo Rua
Proyecto:	Machine Learning aplicado al sector BPO
Tecnologia core:	Google Gemini 2.5 Flash + TF-IDF + K-Means
Cloud:	Google Cloud Platform (GCP)


1. Vision General de la Solucion

La solución propuesta automatiza el análisis de comentarios de encuestas de satisfacción post-llamada en una operación BPO del sector de energía. El sistema procesa los comentarios en tiempo real, clasifica los motivos de insatisfacción utilizando un LLM (Gemini 2.5 Flash), complementa el análisis con clustering semántico no supervisado, y presenta los resultados en dashboards interactivos para la toma de decisiones.

El diseno prioriza tres principios: escalabilidad (serverless), costo-eficiencia (API pay-per-use y tier gratuito de Gemini), y accionabilidad (alertas automaticas en casos criticos).

2. Diagrama de Arquitectura





3. Componentes del Sistema

3.1 Capa de Ingesta

Los comentarios de las encuestas post-llamada se capturan en tiempo real mediante Google Pub/Sub, un sistema de mensajería asincrónica que garantiza la no pérdida de datos y desacopla la ingesta del procesamiento. Los archivos históricos se almacenan en Google Cloud Storage (GCS) para procesamiento batch. Ambos flujos alimentan al pipeline de procesamiento.

3.2 Capa de Procesamiento (NLP + LLM)

Un servicio serverless en Cloud Run se activa con cada nuevo lote de comentarios y ejecuta el pipeline completo: (1) limpieza y normalización del texto, (2) clasificación de motivos de insatisfacción y análisis de sentimiento mediante la API de Gemini 2.5 Flash con prompt engineering estructurado, y (3) almacenamiento de resultados en PostgreSQL. Adicionalmente, un job programado con Cloud Scheduler ejecuta semanalmente el clustering semántico (TF-IDF + K-Means) para recalibrar las agrupaciones con datos acumulados.

3.3 Capa de Almacenamiento

PostgreSQL (Cloud SQL) almacena los comentarios originales, las clasificaciones del LLM, los clusters asignados y los metadatos de cada llamada. Se utiliza PostgreSQL por su soporte nativo de JSON (para almacenar respuestas del LLM), capacidades analíticas avanzadas y compatibilidad con herramientas de visualización.

3.4 Capa de Resultados y Monitoreo

Los resultados se exponen a través de tres canales: (a) un dashboard interactivo en Looker Studio o Power BI que muestra distribución de categorías, tendencias temporales y mapa de calor de sentimiento por categoría con actualización automática; (b) alertas automáticas vía Slack o email para comentarios clasificados como 'muy_negativo', permitiendo intervención inmediata del equipo de calidad; y (c) una API REST construida con FastAPI y desplegada en Cloud Run que permite a otros sistemas internos consultar clasificaciones en tiempo real o acceder a reportes agregados.

4. Stack Tecnológico

Componente	Tecnologia	Justificacion
Orquestacion	Google Cloud Platform	Ecosistema integrado con Gemini API
Procesamiento	Cloud Run / Cloud Functions	Serverless, escalable, costo por uso
LLM	Gemini 2.5 Flash API	Costo-efectivo, rapido, buen rendimiento en espanol
Base de datos	PostgreSQL (Cloud SQL)	Robusto, soporte JSON, consultas analiticas
Cola de mensajes	Google Pub/Sub	Desacoplamiento, garantia de entrega
Dashboard	Looker Studio / Power BI	Visualizacion interactiva, acceso web
API	FastAPI + Cloud Run	Alto rendimiento, documentacion automatica (Swagger)
CI/CD	GitHub Actions	Integracion directa con el repositorio
Monitoreo	Cloud Monitoring	Supervision de costos y latencia de la API
NLP Clasico	Scikit-learn (TF-IDF, KMeans)	Validacion estadistica complementaria

5. Flujo de Datos

Paso	Entrada	Proceso	Salida
1	Comentario crudo (texto)	Limpieza + normalizacion	Texto limpio
2	Texto limpio (lote de 15)	Gemini API (prompt engineering)	JSON: categoria + sentimiento
3	Textos limpios acumulados	TF-IDF vectorizacion	Matriz sparse (docs x features)
4	Matriz TF-IDF	K-Means clustering	Asignacion de cluster por documento
5	Clasificaciones + clusters	Agregacion y cruce	Tabla resumen + validacion cruzada
6	Resultados finales	Dashboard + alertas	Visualizaciones + notificaciones

6. Estimacion de Costos

La arquitectura esta disenada para minimizar costos aprovechando los tiers gratuitos de GCP y la API de Gemini:

Servicio	Tier Gratuito	Costo estimado (bajo volumen)
Gemini 2.5 Flash API	15 RPM / 1M tokens gratis	USD \$0 (< 1000 comentarios/mes)
Cloud Run	2M requests/mes gratis	USD \$0 (bajo volumen)
Cloud SQL (PostgreSQL)	---	~USD \$7/mes (instancia minima)
Pub/Sub	10 GB/mes gratis	USD \$0
Cloud Storage	5 GB gratis	USD \$0
Looker Studio	Gratuito	USD \$0
Total estimado		~USD \$7 - \$15/mes

7. Escalabilidad y Mejoras Futuras

La arquitectura serverless permite escalar horizontalmente sin cambios de infraestructura. A medida que el volumen de comentarios crezca, se pueden implementar las siguientes mejoras:

1. Reemplazar Gemini Flash por un modelo fine-tuneado especifico para el dominio BPO de energia, reduciendo costos de API y mejorando precision en categorias especificas del negocio.
2. Implementar un modelo de embeddings (text-embedding-004 de Google) para clustering semantico mas preciso, reemplazando TF-IDF por representaciones vectoriales densas.
3. Agregar analisis temporal para detectar tendencias y estacionalidad en los motivos de insatisfaccion (por ejemplo, aumento de quejas por cortes en epocas de lluvia).
4. Integrar el sistema con el CRM para enriquecer el analisis con datos del cliente (antiguedad, plan, historial de llamadas) y generar perfiles de riesgo de churn.
5. Implementar A/B testing automatizado para evaluar mejoras en el prompt de clasificacion y medir el impacto en la precision del modelo.